




# LLM 구조 도식화 및 DFX 논문 리뷰(2)




# 목차

- 1. DFA 도식화
- 2. DFA 논문의 문제점 및 한계점

# DFA 도식화

## Decoder Layer 1



# DFX 논문의 한계점 및 문제점

# DFX 논문의 한계점 및 문제점

- 1. 논문 초록 부분에서 DFX가 NVIDIA V100 GPU 대비 5.58배의 속도 향상과 3.99배의 에너지 효율성을 달성했다고 하는데, 현재는 이보다 더 발전된 GPU들이 있는데 발전된 GPU와 DFX 방식과의 비교를 해봐야 할 것 같다.
- 2. 4개의 FPGA를 연결할 때 2개의 QSFP 포트만 제한해서 링 네트워크를 선택했는데, 근데 이렇게 되면 장치가 많아지면 포트가 제한되어 있어서 오히려 지연 시간이 늘어나서 성능이 저해되는 것 같다.