

최성우

Hankuk University of Foreign Studies

The Division of Computer Engineering



목차

- 1. 이번주 수행 과업
- 2. 질문 및 개선점

1. 이번주 수행 과업

- 1. GPTQ를 활용하여 LLM 사전학습 모델을 다운로드하고 양자화한 후 BBS 알고리즘을 적용해서 각각 RA와 zS를 적용했을 때 값들의 변화와 각각의 MSE를 확인해서 엑셀 파일에 저장

1. 이번주 수행 과업

- 모델: facebook/opt-125m(1억 2500만 파라미터)
- 방법: GPTQ(Post-Training Quantization)
- 설정: wikitext2 캘리브레이션 데이터 128샘플, 8-bit 양자화
- 결과 opt125m-8bit.pt 파일로 저장
 - 이때 양자화 시 INT8 정수값 + scales + zeros 함께 저장

1. 이번주 수행 과업

- 대상: 12개 레이어 x 6개 projection = 72개 FC 레이어
- 입력: INT8 정수 가중치
 - ~~~~~